

Anonimizacja danych

k-anonimowość, l-różnorodność, t-bliskość
oraz odporność na Atak Skośności

Zbiory danych: Adult (UCI) · Medical Cost · German Credit (UCI)

Piotr Zapała, Jan Poręba, Maksymilian Neumann

13 kwietnia 2026

Spis treści

1	Wprowadzenie	2
1.1	Zbiory danych	2
1.2	Parametry analizy	2
2	k-anonimowość	2
2.1	Definicja	2
2.2	Wyniki adaptacyjnego wyszukiwania	3
2.3	Wnioski	3
3	l-różnorodność	3
3.1	Definicja	3
3.2	Wyniki	3
3.3	Wnioski	3
4	t-bliskość	4
4.1	Definicja	4
4.2	Adaptacyjne wyszukiwanie optymalnego (k, l, t)	4
4.3	Wnioski	4
5	Atak skośności	4
5.1	Opis ataku	4
5.2	Wyniki pipeline'u	5
5.3	Wykresy analizy podatności	5
5.4	Wykresy ataku po każdym etapie — Adult	7
5.5	Wykresy ataku po każdym etapie — Medical Cost	8
5.6	Wykresy ataku po każdym etapie — German Credit	10
6	Próg t eliminujący atak	11
6.1	Metodologia	11
6.2	Wyniki	11
7	Wnioski ogólne	13
7.1	Hierarchia ochrony	13
7.2	Porównanie datasetów	13
7.3	Praktyczne rekomendacje	14

1 Wprowadzenie

Celem niniejszego sprawozdania jest analiza porównawcza trzech technik anonimizacji danych tabelarycznych:

- **k-anonimowość** — każdy rekord jest nieodróżnialny od co najmniej $k-1$ innych rekordów ze względu na quasi-identyfikatory.
- **l-różnorodność** — w każdej klasie równoważności atrybut wrażliwy przyjmuje co najmniej l dobrze reprezentowanych wartości (entropia $H(EC_i) \geq \log l$).
- **t-bliskość** — rozkład atrybutu wrażliwego w każdej klasie jest bliski rozkładowi globalnemu (dystans $\leq t$).

Analizę przeprowadzono na trzech zbiorach danych, a wyniki oceniono pod kątem skuteczności **Ataku Skośności**.

1.1 Zbiory danych

Tabela 1: Charakterystyka zbiorów danych

Dataset	Rekordy	Quasi-identyfikatory	Atr. wrażliwy	Typ
Adult (UCI)	47 592	education_grp, sex, race, age	income	4 warianty
Medical Cost	1 337	sex, region, age, bmi	charges_cat	4 kwartyle
German Credit	1 000	personal_status, housing, foreign_worker, age	checking_status	4 kategorie

1.2 Parametry analizy

Kolumny numeryczne (wiek, BMI) generalizowano metodą kwantylową (`pd.qcut`), która równomiernie rozkłada rekordy między kubelki. Optymalną liczbę kubelków wyznaczano adaptacyjnie. Próg ataku skośności ustalono na $\tau = 0,10$.

2 k-anonimowość

2.1 Definicja

Zbiór danych spełnia **k-anonimowość**, jeśli każda klasa równoważności EC_i (zbiór rekordów o identycznych wartościach quasi-identyfikatorów) zawiera co najmniej k rekordów:

$$\forall i: |EC_i| \geq k$$

Realizacja przez *supresję*: klasy z $|EC_i| < k$ są usuwane w całości.

2.2 Wyniki adaptacyjnego wyszukiwania

Tabela 2: Optymalne parametry k-anonimowości ($l=2$, bez t-bliskości)

Dataset	k opt.	age_bins	bmi_bins	Zachowane [%]
Adult	5	2	—	99,9%
Medical Cost	20	2	2	100,0%
German Credit	2	2	—	97,5%

2.3 Wnioski

- **Adult**: zbiór duży (47 592 rek.), generalizacja do 2 kubeków wiekowych i 2 klas edukacji tworzy naturalnie duże klasy równoważności. Przy $k = 5$ supresja wynosi zaledwie 0,1% — praktycznie bezstratna.
- **Medical Cost**: mały zbiór (1 337 rek.), ale tylko 32 klasy. Nawet przy $k = 20$ każda klasa ma ≥ 25 rekordów — brak supresji.
- **German Credit**: najmniejszy zbiór (1 000 rek.), 3 kategorięczne QI dają wiele małych klas. Przy $k = 2$ utrata 2,5% — dobry wynik, lecz $k = 2$ oznacza słabą ochronę (zaledwie 2 rekordy w klasie).
- **Kluczowa obserwacja**: sama k-anonimowość nie chroni przed wnioskowaniem o atrybucie wrażliwym — klasa z $k = 5$ rekordami może mieć 4 z tą samą wartością atrybutu wrażliwego.

3 l-różnorodność

3.1 Definicja

Klasa równoważności EC_i spełnia **l-różnorodność** (entropijną), jeśli entropia Shannona rozkładu atrybutu wrażliwego jest wystarczająca:

$$H(EC_i) = - \sum_{s \in S} P(s|EC_i) \log P(s|EC_i) \geq \log l$$

3.2 Wyniki

Tabela 3: Wpływ l-różnorodności na zachowanie rekordów (optymalne k)

Dataset	k	l	Zachowane po k	Zachowane po k+l
Adult	5	2	100,0%	99,9%
Medical Cost	10	2	100,0%	100,0%
German Credit	5	2	97,6%	97,1%

3.3 Wnioski

- **Adult**: income ma 4 warianty ($\leq 50K$, $\leq 50K.$, $> 50K$, $> 50K.$) — l-różnorodność spełniona przy supresji tylko 0,1%. Entropia minimalna $0,709 > \log 2 = 0,693$.

- **Medical Cost:** charges_cat pochodzi z qcut, każda kategoria ma globalnie $\approx 25\%$ rekordów. Klasy naturalnie spełniają $l = 2$ — brak supresji.
- **German Credit:** checking_status ma nierównomierny rozkład (39% no account, 6% ≥ 200 DM). Supresja 0,5% — l-różnorodność działa efektywnie.
- **Kluczowa obserwacja:** l-różnorodność *nie chroni* przed atakiem skośności gdy globalny rozkład atrybutu jest równomierny (Medical Cost) — entropia może być wysoka, a rozkład lokalny nadal silnie odbiega od globalnego.

4 t-bliskość

4.1 Definicja

Klasa EC_i spełnia **t-bliskość**, jeśli dystans między rozkładem atrybutu wrażliwego w klasie a rozkładem globalnym nie przekracza t :

$$d(P(S|EC_i), P(S)) \leq t$$

Dla atrybutów kategorycznych stosujemy *dystans wariacyjny* $\frac{1}{2} \sum_s |P_i(s) - P_G(s)|$, dla numerycznych *Earth Mover's Distance* (EMD).

4.2 Adaptacyjne wyszukiwanie optymalnego (k, l, t)

Tabela 4: Optymalne parametry z t-bliskością

Dataset	k	l	t	age_bins	bmi_bins	Zachowane [%]
Adult	5	2	0,30	2	—	89,1%
Medical Cost	10	2	0,30	2	2	62,2%
German Credit	5	2	0,30	2	—	96,2%

4.3 Wnioski

- We wszystkich trzech datasetach optymalne $t = 0,30$, zachowując odpowiednio 89%, 62% i 96% rekordów.
- **Medical Cost** traci 38% rekordów przy $t = 0,30$ — wynika to z dużej demograficznej różnorodności kosztów leczenia.
- **German Credit** traci tylko 4% przy $t = 0,30$ — najlepszy kompromis spośród trzech datasetów.

5 Atak skośności

5.1 Opis ataku

Atak skośności wykorzystuje fakt, że rozkład atrybutu wrażliwego w klasie równoważności może istotnie różnić się od rozkładu globalnego. Atakujący, znając quasi-identyfikatory

ofiary, wyznacza jej klasę i porównuje histogram lokalny z globalnym:

$$\text{atak udany} \iff \exists s: |P_i(s) - P_G(s)| > \tau$$


Przy $\tau = 0,10$ każde odchylenie powyżej 10 pkt. proc. uznawane jest za wyciek informacji.

5.2 Wyniki pipeline'u


Tabela 5: Skuteczność ataku skośności po kolejnych etapach anonimizacji

Dataset	Etap	Rekordy	Klas	Podatnych	Max odch.
Adult	k=5	100,0%	40	28 (70,0%)	0,306
	k=5, l=2	99,9%	39	27 (69,2%)	0,306
	k=5, l=2, t=0,3	89,1%	35	19 (54,3%)	0,272
Medical Cost	k=10	100,0%	32	32 (100,0%)	0,364
	k=10, l=2	100,0%	32	32 (100,0%)	0,364
	k=10, l=2, t=0,3	62,2%	19	19 (100,0%)	0,307
German Credit	k=5	97,6%	20	13 (65,0%)	0,271
	k=5, l=2	97,1%	19	12 (63,2%)	0,272
	k=5, l=2, t=0,3	96,2%	18	12 (66,7%)	0,199


5.3 Wykresy analizy podatności



Rysunek 1: Adult — lewy panel: % podatnych klas vs k dla k -anonimowości i $k+l$ -różnorodności. Obie krzywe prawie się pokrywają — l -różnorodność nie poprawia ochrony przed atakiem. Prawy panel: porównanie trzech etapów pipeline dla optymalnych $k = 5$, $l = 2$, $t = 0,3$.




Rysunek 2: Medical Cost — lewy panel: podatność stale 100% niezależnie od k i l . Prawy panel: dopiero t -bliskość ($t = 0,3$) redukuje rekordy do 62%, ale podatność pozostaje 100%.




Rysunek 3: German Credit — lewy panel: podatność maleje z k , l -różnorodność daje nieznaczną poprawę. Prawy panel: t -bliskość nie redukuje znacząco rekordów (96%), ale też nie eliminuje ataku.


5.4 Wykresy ataku po każdym etapie — Adult



Rysunek 4: Adult po k -anonimowości ($k = 5$). Najbardziej podatna klasa: (Higher educ., Male, White, starszy wiek) — $P_i(>50K) = 0,47$ vs $P_G(>50K) = 0,16$, odchylenie 0,31.




Rysunek 5: Adult po l -różnorodności ($l = 2$). Liczba podatnych klas spada z 28 do 27 — l -różnorodność prawie nie pomaga. Najbardziej podatna klasa pozostaje ta sama.




Rysunek 6: Adult po t -bliskoŹci ($t = 0.3$). Podatnych klas 19 (54%) — atak nadal skuteczny. Max odchylenie $0.27 > \tau = 0.10$. Atak dotyczy teraz innej klasy: (Higher, Male, Amer-Indian-Eskimo).


5.5 Wykresy ataku po kaŹdym etapie — Medical Cost



Rysunek 7: Medical Cost po k -anonimowoŹci ($k = 10$). Wszystkie 32 klasy podatne (100%). Podatna klasa (female, southwest, starszy, wyŹsze BMI): High=0,61 vs 0,25 globalnie.




Rysunek 8: Medical Cost po l -różnorodności ($l = 2$). Identyczny wynik — 100% klas podatnych. `charges_cat` jest równomierny globalnie, więc entropia w każdej klasie jest wysoka mimo lokalnej dominacji.




Rysunek 9: Medical Cost po t -bliskości ($t = 0,3$). Liczba klas spada z 32 do 19 (zachowano 62% rekordów), ale wszystkie 19 pozostałych nadal podatne. Atak zmienia charakter — teraz Low dominuje w podatnych klasach.


5.6 Wykresy ataku po każdym etapie — German Credit



Rysunek 10: German Credit po k -anonimowości ($k = 5$). 13 z 20 klas podatnych (65%). Podatna klasa: (male single, own, no, starszy wiek) — <0 DM=0,44 vs 0,27 globalnie.



Rysunek 11: German Credit po l -różnorodności ($l = 2$). 12 z 19 klas podatnych (63%). Minimalny efekt — l -różnorodność usuwa tylko klasy z jedną dominującą wartością checking_status.



Rysunek 12: German Credit po t -bliskości ($t = 0,3$). Max odchylenie spada do 0,199, ale nadal $> \tau = 0,10$. Do wyeliminowania ataku potrzebne $t \leq 0,10$ (zachowanie 36% rekordów).

6 Próg t eliminujący atak


6.1 Metodologia

Dla każdego datasetu przeskanowano siatkę $t \in \{0,05; 0,08; 0,10; 0,12; 0,15; 0,18; 0,20; 0,25; 0,30; 0,35\}$. Dla każdego t zastosowano pipeline $k \rightarrow l \rightarrow t$ i sprawdzono czy atak jest skuteczny (czy istnieje klasa z odchyleniem $> \tau$).


6.2 Wyniki

Tabela 6: Próg t^* eliminujący atak skośności ($\tau = 0,10$)


Dataset	k	l	t^*	Rekordy przy t^*	Uwagi
Adult	5	2	0,10	27,7%	Wąskie okno $t \in [0,05; 0,10]$
Medical Cost	10	2	0,25	11,7%	Przy $t < 0,25$ brak rekordów
German Credit	5	2	0,10	36,3%	Najlepszy kompromis



Rysunek 13: Adult: próg $t^* = 0,10$ eliminuje atak przy zachowaniu 27,7% rekordów. Widoczne wąskie bezpieczne okno $t \in [0,05; 0,10]$ — powyżej $t = 0,12$ podatność gwałtownie rośnie.



Rysunek 14: Medical Cost: $t^* = 0,25$ z zachowaniem jedynie 11,7% rekordów. Przy $t < 0,25$ t-bliskość usuwa wszystkie rekordy. Skokowy charakter krzywej — brak płynnego tradeoffu.



Rysunek 15: German Credit: $t^* = 0,10$ z zachowaniem 36,3% rekordów — najlepszy kompromis. Przy $t = 0,10$ krzywa podatności dotyka zera przy 36% użyteczności.

7 Wnioski ogólne

7.1 Hierarchia ochrony

Trzy metody tworzą hierarchię rosnącej ochrony i rosnącego kosztu:

1. **k-anonimowość**: chroni przed identyfikacją konkretnej osoby, ale nie przed wnioskowaniem o atrybucie wrażliwym. Mała utrata danych.
2. **l-różnorodność**: wymaga zróżnicowania atrybutu wrażliwego w klasie. Skuteczna gdy atrybut globalnie nierównomierny. Przy równomiernym atrybucie (Medical Cost) praktycznie nie działa.
3. **t-bliskość**: bezpośrednio ogranicza odchylenie rozkładu lokalnego od globalnego. Gdy $t \leq \tau$, istnieje *formalna gwarancja* że atak skośności jest niemożliwy — żadna klasa nie może mieć odchylenia większego niż $t \leq \tau$. Empirycznie próg t^* eliminujący atak może być większy niż τ (np. Medical Cost: $t^* = 0,25 > \tau = 0,10$), gdy po supresji przypadkowo pozostają tylko klasy o małych odchyleniach. W obu przypadkach ochrona wiąże się ze znaczną utratą danych.

7.2 Porównanie datasetów

- **Adult**: duży dataset, tani k i l, ale t-bliskość $\leq 0,10$ usuwa $\sim 72\%$ rekordów. Podatność wynika z silnej korelacji wykształcenia, płci i rasy z dochodem.
- **Medical Cost**: strukturalnie najtrudniejszy. L-różnorodność bezużyteczna, t-bliskość bardzo kosztowna. Wynika to z tego, że koszty leczenia są silnie skorelowane z paleniem (cecha poza QI).

- **German Credit:** najlepszy kompromis. T-bliskość z $t = 0,10$ eliminuje atak przy zachowaniu 36% danych — akceptowalny koszt dla wielu zastosowań.

7.3 Praktyczne rekomendacje

- Cel: anonimizacja identyfikacyjna — wystarczy k -anonimowość ($k \geq 5$).
- Cel: ochrona przed wnioskowaniem statystycznym — dodać l-różnorodność (skuteczna gdy atrybut nierównomierny globalnie).
- Cel: ochrona przed atakiem skośności — t-bliskość z $t \leq \tau$ daje formalną gwarancję, jednak empiryczny próg t^* eliminujący atak bywa większy niż τ (zależy od struktury danych). W każdym przypadku należy liczyć się z utratą 60–90% rekordów.
- Adaptacyjne dobieranie liczby kubelków generalizacji numerycznej pozwala zachować więcej rekordów niż stałe progi (np. dekady wiekowe).