

Reprezentacje grafowe jako obfuskacja danych: prywatność i klastrowalność na ENZYMES, PROTEINS i CIFAR

1 Wprowadzenie i cel

Punktem wyjścia było klastrowanie reprezentacji grafowych cząsteczek: ENZYMES (6 klas) i PROTEINS_full (2 klasy), deskryptory całografowe (topo, WL, graph2vec, spektralne) plus sonda nadzorowana. Pytanie pierwotne: czy klasa jest zakodowana w strukturze grafu. Równolegle powstała ścieżka obrazowa: CIFAR-10 $\rightarrow$ graf SLIC (węzeł = superpiksel, krawędź = bliskość i podobny kolor), oraz pomysł grafów losowych (ER/dropedge) jako reprezentacji. Wcześniej pokazaliśmy, że klasa jest obecna w reprezentacji grafowej (sonda nadzorowana ją wykrywa), ale klastrowanie bez etykiet wydobywa mało; to przyjmujemy za punkt wyjścia. W tej iteracji zmieniamy perspektywę na **prywatność**: graf jako reprezentacja, która ukrywa obiekt. Pytamy nie tylko, czy klasa jest wykrywalna bez etykiet (użyteczność), ale też ile da się z reprezentacji odzyskać (odwracalność, atak rekonstrukcyjny). Wszystkie liczby policzyliśmy na pełnych danych odpornym atakiem (RidgeCV+MLP); katalogi `results_FINAL_*`.

2 Co nowego w tej iteracji

- **FGSD**: deskryptor strukturalny, histogram odległości spektralnych (biharmonicznych) między parami węzłów. Zależy tylko od topologii (zero cech węzłów), więc „czysto strukturalny”.
- **edge-DP i feature-DP**: dwa mechanizmy obfuskacji. edge-DP losowo przerzuca *krawędzie* (siła ε), feature-DP dodaje szum gaussowski o odchyleniu σ do *cech węzłów*. Działają na rozłącznych częściach grafu, stąd „ortogonalne”.
- **Odporny atak rekonstrukcyjny** (metryka `recon_leak` $\in [0, 1]$): R^2 regresora, który z embeddingu odtwarza treść obiektu, czyli uśrednione cechy węzłów (to samo, czym jest `attr`). Wyżej znaczy łatwiej odtworzyć, czyli gorsza prywatność. Dla `attr` odtworzenie jest prawie tożsamością, więc jego wyciek jest oczekiwany; istotne jest, że deskryptory strukturalne tych cech nie odtwarzają. Bierzemy silniejszy z RidgeCV i MLP, co usuwa artefakt słabego MLP ($R^2 = -8,58$ na FGSD).
- **Wizualny atak inwersyjny**: regresor odtwarza cały obraz (kolor każdego superpiksela), nie tylko średnią treść.
- **Oracle LDA**: rzut embeddingu na oś dyskryminującą klasy. *Używa etykiet*, więc daje górną granicę separowalności, nie wynik uczciwy. Mówi, ile sygnału klasy w ogóle jest w embeddingu.
- **rand_ens**: uśrednia deskryptor strukturalny po M losowych wariantach grafu (dropedge/ER). Sprawdza, czy losowa struktura zastąpi prawdziwą.

3 Ustawienie eksperymentów

Trzy zbiory: ENZYMES (600 grafów), PROTEINS_full (1113), CIFAR-10 3 klasy 0/1/8 (SLIC, 1500). Każdy graf kodujemy dwoma strumieniami: *strukturalnym* (deskryptory topologii: topo, WL, graph2vec, spektralne, FGSD) i *atrybutowym* (`attr`: uśrednione cechy węzłów, czyli kolor obrazu lub atrybuty białka, a więc **treść** obiektu bez struktury). Metryki: `km_ARI/km_NMI` mierzą zgodność klastrów (KMeans, *bez etykiet*) z prawdziwymi klasami; `probe_acc` mierzy liniową separowalność klas (regresja logistyczna, CV, *z etykietami*). Wysokie `probe_acc` przy niskim ARI oznacza, że klasa jest separowalna, ale niewykrywalna bez nadzoru. `recon_leak` $\in [0, 1]$ = prywatność ($\downarrow$ = prywatniej). Wszystkie metody/hiperparametry wybieramy **bez użycia etykiet** (label-free: silhouette albo CV sondy); ARI/NMI raportujemy tylko jako wynik końcowy.

Zbiory pełnią różne role i nie każdy eksperyment liczymy na każdym (Tab. 1).

eksperyment	ENZYMES	PROTEINS	CIFAR
benchmark reprezentacji	✓	✓	✓ (+ rgb/hog)
bateria klastrowań	✓	✓	✓
recon_leak (odporny atak)	✓	✓	✓
edge-DP	—	✓	✓
feature-DP	—	✓	—
siatka 2D (struktura $\perp$ treść)	—	✓	—
ablacja struktura vs losowość	✓	✓	—
rand_ens	✓	✓	—
oracle LDA	—	✓	✓
atak inwersyjny (obraz)	—	—	✓
stabilność po seedach	częśc.	✓	✓

Tabela 1: Co liczymy na którym zbiorze. PROTEINS = główny, najczystszy wynik i pełna oś prywatności; CIFAR = ścieżka obrazowa (wygląd vs struktura, atak inwersyjny); ENZYMES = trudny sufit i kontrola.

4 Wyniki

(A) Separowalność $\neq$ klastrowalność


Teza: klasa jest liniowo separowalna, ale nie pokrywa się z kierunkami największej wariancji danych, więc klastrowanie bez etykiet wydobywa mało. Na wszystkich zbiorach **probe_acc** jest wyraźnie powyżej poziomu losowego przy niskim ARI. Bateria klastrowań (GMM, UMAP, whitening, jądro WL) daje co najwyżej niewielki zysk (CIFAR 0,082 $\rightarrow$ 0,085). Dowodzi tego **oracle LDA** (rzut na oś klasy, używa etykiet): na PROTEINS jądro WL bez etykiet daje 0,040, a oracle **0,315** ($\times 8$); na CIFAR w 0,082 wobec oracle **0,220** ($\times 2,6$). Sygnał klasy jest w reprezentacji, lecz poza głównymi kierunkami wariancji. *Oracle to górna granica z etykietami, nie wynik uczciwy.*

(B) Czysta struktura jest prywatna, a attr wycieka


Teza: z deskryptora czysto strukturalnego prawie nie da się odtworzyć treści, ze strumienia atrybutowego już tak. PROTEINS: fgssd **recon_leak** = 0,042, topo 0,099, w 0,103 wobec attr 0,764. ENZYMES: w 0,077 wobec attr 0,791. CIFAR: fgssd 0,048, topo 0,323 wobec attr 0,885. Dla fgssd atak nie odtwarza treści lepiej niż losowo (**recon_leak** ≈ 0), dla attr odtwarza ją w około 80%. Graf strukturalny ukrywa więc obiekt, a strumień treści go ujawnia. Na PROTEINS **fgssd jest najlepszy na obu osiach jednocześnie**: najlepsze ARI (0,135) i najniższy wyciek (0,042) (Rys. 1); oba stabilne po 5 seedach ($0,136 \pm 0,001$ i $0,046 \pm 0,002$). Wizualny atak inwersyjny (Rys. 3) potwierdza to wprost: z attr odtwarza się rozpoznawalną paletę obiektu (SSIM 0,198, MSE 0,037), a z fgssd rekonstrukcja jest nieinformatywna (MSE 0,058).

(C) Dwie niezależne osie prywatności: struktura $\perp$ treść

Teza: edge-DP chroni strukturę, feature-DP chroni treść; osie niezależne. feature-DP (Rys. 2): **recon_leak** dla attr maleje monotonicznie 0,764 $\rightarrow$ 0,485 ($\sigma = 0 \rightarrow 4$), a topo/w 0,099/0,103). edge-DP: **recon_leak** dla attr jest *dokładnie stały* (0,764 dla każdej siły), bo attr czyta tylko cechy węzłów. Siatka 2D (Rys. 2, prawo): wyciek treści nie zmienia się wzdłuż osi edge-DP (odch. 0,000) i maleje wzdłuż feature-DP. Prywatność struktury i treści regulujemy więc *osobno*: obfuskacja krawędzi nie tyka treści, a szum cech nie tyka struktury. Pod odpornym atakiem feature-DP obniża wyciek umiarkowanie (0,764 $\rightarrow$ 0,485), nie do zera, bo silny atakujący wyciąga więcej.



Rysunek 1: Każdy punkt to jedna reprezentacja: oś X = wyciek (atak), oś Y = jakość klastrowania. Deskryptory strukturalne leżą w strefie prywatnej ($\text{recon_leak} < 0,2$); attr (treść) wycieka ($\text{recon_leak} = 0,764$). Wniosek: fgds jest najlepszy na obu osiach jednocześnie.




Rysunek 2: Lewo: feature-DP obniża odwracalność treści (attr 0,76 $\rightarrow$ 0,49), struktura pozostaje płaska. Prawo: siatka 2D; $\text{recon_leak}[\text{attr}]$ zależy wyłącznie od feature-DP i nie zmienia się względem edge-DP (poziome pasy).

(D) Struktura > wygląd na CIFAR

Teza: struktura grafu niesie sygnał klasy, którego sam wygląd nie chwyta. W klastrowaniu bez etykiet wl ARI 0,082 wyraźnie bije hog (0,008) i jest nieco lepsze od rgb (0,071); ta druga różnica mieści się jednak w rozrzucie między losowymi seedami ($\pm 0,008$) (rgb to średni kolor, hog to histogram gradientów, oba opisują wygląd bez grafu). Mocniejszy dowód daje ablacja struktura wobec losowości (graf losowy jako reprezentacja): prawdziwa topologia (fgsd PROTEINS 0,135) daje około $2\times$ więcej niż losowa (ER 0,065, droppedge 0,058), czyli sygnał niesie sama struktura, nie fakt istnienia krawędzi. Na ENZYMES różnica jest mała (wl 0,046 wobec $\sim 0,038$), bo seed WL to etykiety węzłów (typ), zachowane przy obfuskacji krawędzi.

Finalne leaderboard

Tabela 2 zbiera wyniki. Na PROTEINS fgds ma najwyższe ARI i najniższy wyciek zarazem. Na CIFAR najwyższe ARI ma attr (0,124 > wl 0,082): gdyby liczyła się tylko klastrowalność, wygrałby attr, ale odrzucamy go jako lidera, bo wycieka (recon_leak 0,885). Najlepsza struktura (wl/g2v,



Rysunek 3: Wizualny atak inwersyjny (CIFAR). attr odtwarza paletę obiektu i degradowe pod feature-DP; rekonstrukcja z fgds (czysta topologia) jest nieinformatywna; wl niesie kolor, bo jego etykiety węzłów pochodzą z koloru. Bezwzględne SSIM niskie, bo embeddingi są permutacyjnie niezmiennicze (niezależne od numeracji węzłów, brak układu przestrzennego).

ARI 0,082) też *wycieka* ($\text{recon_leak} \approx 0,7$), bo jej etykiety węzłów opisują kolor, więc na CIFAR struktura nie jest prywatna. attr wszędzie ma najwyższy wyciek (0,76–0,89).

Tabela 3 podsumowuje, gdzie każdy wniosek jest widoczny: A i B na wszystkich zbiorach; C na PROTEINS; D1 (wygląd) tylko na CIFAR, bo tylko tam jest oś wyglądu; D2 (ablacja struktura vs losowość) na grafach molekularnych.

5 Mocne i słabe strony

- **Mocne:** fgds na PROTEINS osiąga jednocześnie najlepsze ARI ($0,136 \pm 0,001$) i najniższy wyciek ($0,046 \pm 0,002$), stabilnie po 5 seedach. Liczby prywatności (recon_leak) są stabilne ($\pm 0,002$ – $0,007$). Siatka 2D czysto rozdziela strukturę od treści (odchylenie 0,000).
- **Gdzie nie wyszło:** ENZYMES ma sufit ARI 0,046 (zbiór wewnętrznie trudny). Na CIFAR wl/g2v *nie są prywatne* ($\text{recon_leak} \approx 0,7$, bo ich etykiety węzłów kodują kolor), więc struktura niesie tu wygląd. ARI wl na CIFAR jest wrażliwe na losowy seed ($\pm 0,008$, z podpróbki).
- -label-rich na CIFAR **nie skaluje**: zysk z małej próbki znika przy 1500 grafach.
- Komplementarne optimum fuzji struktura $\oplus$ treść (PROTEINS 0,155, CIFAR 0,130) jest **nieselektywny label-free**, więc nie liczymy go jako wynik uczciwy.
- rand_ens bije bazowe topo (PROTEINS 0,089 wobec 0,080), ale nie lidera fgds, a silhouette go nie preferuje. Wariant z bazą wl szkodzi.
- Wizualny atak: bezwzględne SSIM niskie ($\sim 0,2$). Embedding całego grafu nie zależy od numeracji węzłów (jest permutacyjnie niezmienniczy), więc nie koduje położenia, a atak odtwarza kolor, nie kształt.
- feature-DP pod odpornym atakiem obniża wyciek umiarkowanie ($0,764 \rightarrow 0,485$), nie do zera.

6 Podsumowanie

Graf jako reprezentacja realnie ukrywa obiekt: z czystej struktury (fgds) nie da się odtworzyć treści ($\text{recon_leak} = 0,042$ wobec attr 0,764), a wizualny atak daje szum. Klasa nadal tam jest (oracle

PROTEINS_full (1113)				
metoda	km_ARI	km_NMI	probe_acc	recon_leak ↓
fgsd	0,135	0,086	0,691	0,042
rand_ens (topo, M=10)	0,089	0,072	0,724	0,082
topo	0,080	0,063	0,741	0,099
wltopo	0,080	0,063	0,750	0,160
netlsd	0,074	0,056	0,733	0,058
wl	0,040	0,026	0,725	0,103
attr (treść)	0,037	0,026	0,748	0,764
<i>oracle LDA (etykiety)</i>	<i>0,315</i>	<i>0,227</i>	—	—
CIFAR-10 0/1/8 (1500, grafy z obrazu)				
metoda	km_ARI	km_NMI	probe_acc	recon_leak ↓
wl + GMM-full	0,085	0,080	0,573	0,712
wl + KMeans	0,082	0,086	0,573	0,712
g2v + KMeans	0,082	0,081	0,587	0,651
attr (treść)	0,124	0,116	0,633	0,885
rgb (wygląd)	0,071	0,073	0,520	0,441
hog (wygląd)	0,008	0,009	0,718	0,264
<i>oracle LDA (etykiety)</i>	<i>0,220</i>	<i>0,194</i>	—	—
ENZYMES (600), sufit trudny				
metoda	km_ARI	km_NMI	probe_acc	recon_leak ↓
wl	0,046	0,086	0,403	0,077
g2v	0,034	0,060	0,332	0,099
topo	0,030	0,059	0,302	0,002
attr (treść)	0,032	0,056	0,490	0,791

Tabela 2: Leaderboardy uczciwe (selekcja label-free). ↓ przy **recon_leak**: niżej = prywatniej. Poziom losowy **probe_acc**: ENZYMES $\approx 0,17$ (6 klas), PROTEINS $\approx 0,59$ (baseline większościowy), CIFAR $\approx 0,33$ (3 klasy); **probe_acc** czytamy względem nich (np. ENZYMES wl 0,40 to $\sim 2,4\times$ poziomu losowego, nie „słabo”). Oracle LDA używa etykiet, daje więc górną granicę separowalności, nie wynik uczciwy. Na CIFAR wl/g2v **nie są prywatne** (**recon_leak** $\approx 0,7$): ich etykiety węzłów opisują kolor.

LDA podnosi ARI do $8\times$), ale leży poza osią wariancji, więc klastrowanie bez etykiet wydobywa mało. Prywatnością steruje się dwuosiowo: edge-DP (struktura) i feature-DP (treść) działają niezależnie. Główne zastrzeżenie: na grafach z obrazu reprezentacja strukturalna oparta na kolorze (wl) nie jest prywatna.

wniosek	ENZYMES	PROTEINS_full	CIFAR-10
A separowalność $\neq$ klastrowalność	✓	✓✓($\times 8$)	✓($\times 2,6$)
B czysta struktura prywatna, attr wycieka	✓	✓✓	✓
C dwie osie prywatności (struktura $\perp$ treść)	—	✓✓	✓(edge-DP)
D1 struktura $>$ wygląd	—	—	✓✓
D2 struktura $>$ losowość (ablacja)	✓	✓✓	—

Tabela 3: Gdzie każdy wniosek jest pokazany. Oznaczenia: ✓✓ = najmocniej, ✓ = pokazany, „—” = świadomie nieobecny (ENZYMES i PROTEINS nie mają osi wyglądu; obie osie prywatności pokazujemy na PROTEINS jako reprezentatywnym). Wnioski A i B trzymają na wszystkich trzech zbiorach.